

## 第五章 问答摘要与推理-项目模型算法提升

### HCT NLP Week 5

#### 问答摘要与推理- 项目模型算法提升

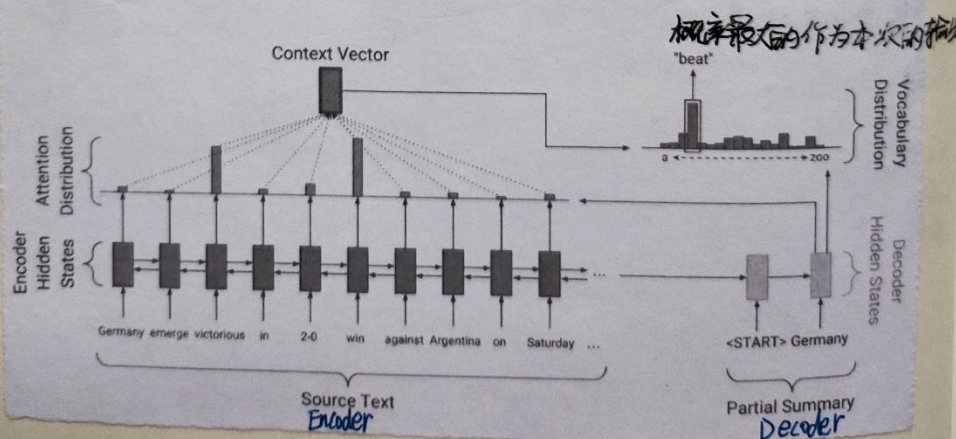
##### Outline

- OOV 和Word-repetition<sup>词语重复</sup>解决
- Training Strategies
- 抽提式文本摘要基本方法
- 相关代码实践

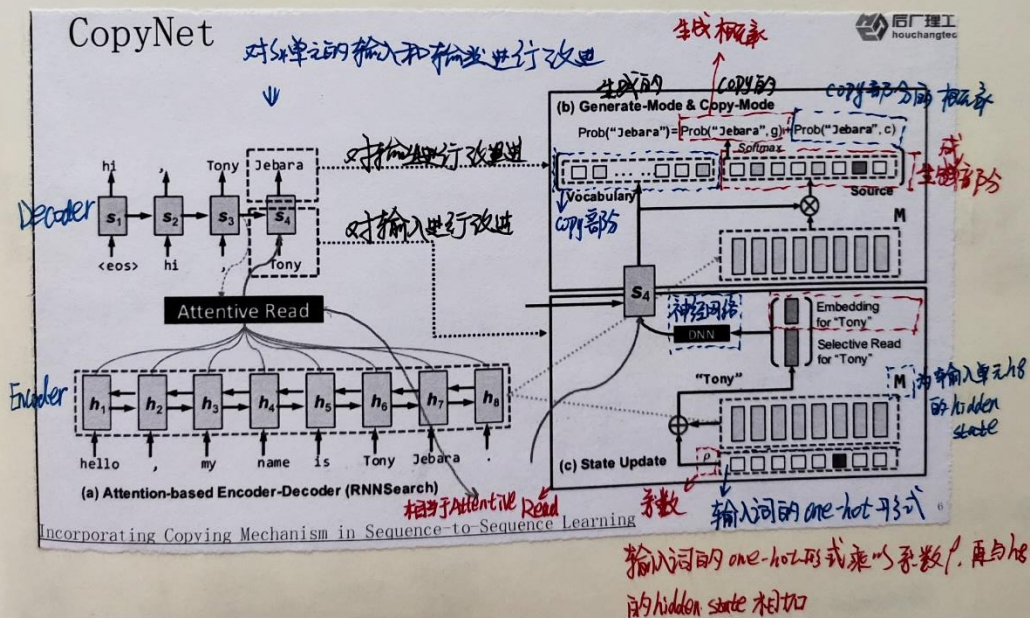
##### Outline

- OOV 和Word-repetition解决
- Training Strategies
- 抽提式文本摘要基本方法
- 相关代码实践

#### 典型的seq2seq



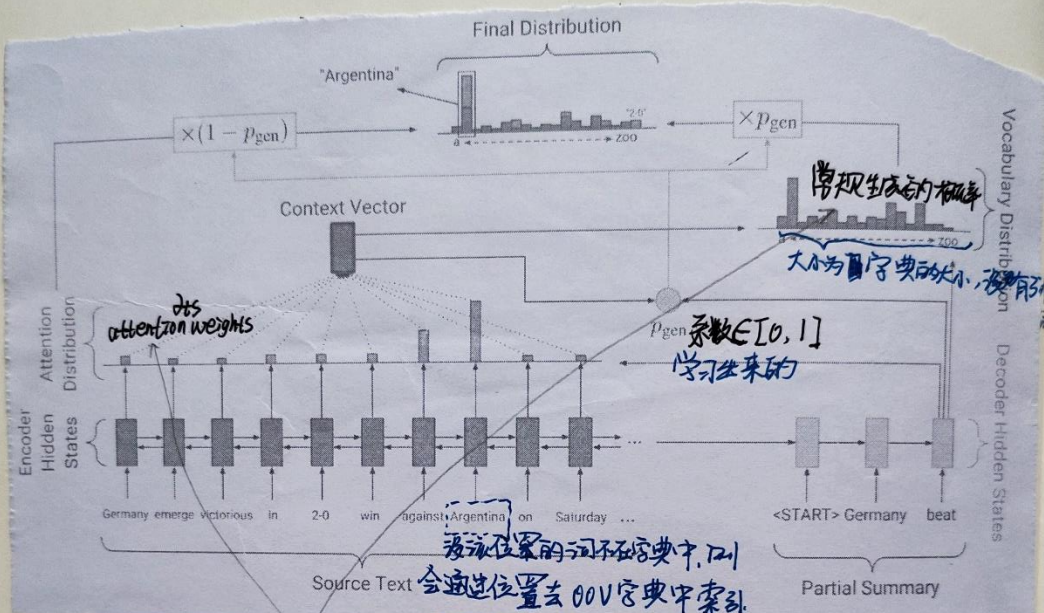
through time





# PGN (Pointer-Generator Networks)

用于解决 OOV 问题



$$p_{gen} = \sigma (w_h^T \times h_t + w_s^T \times s_t + w_x^T \times x_t + b)$$

$\downarrow$  Sigmoid  $\in (0, 1)$      Context vector     decoder hidden     偏置  
 $\downarrow$  会选位置去 OOV 字典中索引     输入的词向量 embedding

因为  $w_1, w_2, w_3$  也行只是写法问题  
 $w_h, w_s, w_x$  为神经网络权重

$$p_{wv} = p_{gen} \cdot p_{vocab}(w) + (1 - p_{gen}) \cdot \frac{w_{des}}{\sum_{i:w_i=w} w_i}$$

$\downarrow$  常规输出概率     即输入词对应的 attention weight

## PGN 特点

1. pointer-generator network能够很容易的复制输入的文本内容，可以通过Pgen 来调节。
2. pointer-generator network能够从输入的文本内容中复制OOV词汇，这是最大的优点，这个也可以采用更小的词汇表vocabulary，较少计算量和存储空间。
3. pointer-generator network训练会更快，在seq2seq训练过程中用更少的迭代次数就能取得一样的效果。

Get To The Point: Summarization with Pointer-Generator Networks

## Repetition Handling 解决词语重复问题

model generated summaries suffer from both word-level and sentence-level repetitions.

Temporal Attention


Intra-decoder Attention

这两种方法应用的很少

★ Coverage (机器翻译中用得最多) 减少生成复词，对已生成的词做一个惩罚和

Coverage:

①  $C_t^t = \sum_{s=0}^{t-1} d_{ts}$  到 t 位置的 Coverage 等于从 0 位置到 t-1 位置的 attention weights 的和  
其中  $C_0 = 0, C_1 = 1$ ; G 为一个非标准的分布



$$C_t^t = U^T \cdot \tanh(W_h h_t + W_c C_t^{t-1} + b)$$

Annotations:   
 $U^T$ : 分数 (score)   
 $\tanh$ : tanh 激活函数   
 $W_h$ : 权重   
 $h_t$ : encoder hidden state   
 $W_c$ : 权重   
 $C_t^{t-1}$ : coverage 偏置   
 $b$ : bias   
 $Dense()$ : 连接层   
 $\tanh$ : 用 tanh 控制   
 $hidden$ : hidden state   
 $decoder$ : decoder hidden state

注：一层的全连接层为一个矩阵 [20]

trick: 在解码时加 trigram block

$$CovLoss_t = \sum \min(d_{ts}, C_t^t) \quad \text{Coverage loss}$$

$$Loss_t = -\log p(w_t) + \lambda \sum \min(d_{ts}, C_t^t) \quad \text{最终 loss}$$

↑ 固定系数值 0.5, 1



# Outline

- OOV 和 Word-repetition 解决
- Training Strategies
- 抽提式文本摘要基本方法
- 相关代码实践

## TRAINING STRATEGIES 训练策略

### A. Word-Level Training 词语级别的训练

two different methods for avoiding the problem of exposure bias.

1) Cross-Entropy Training (XENT) 交叉熵 (loss 函数用交叉熵)

teacher forcing 方法 ~~会造成~~ exposure bias

2) Scheduled Sampling 避免 exposure bias

是一种解决训练和生成时输入数据分布不一致的方法。在训练早期该方法主要使用目标序列中的真实元素作为解码器输入，可以将模型从随机初始化的状态快速引导至一个合理的状态。随着训练的进行，该方法会逐渐更多地使用生成的元素作为解码器输入，以解决数据分布不一致的问题。该方法应用在模型的训练阶段，生成阶段不使用。

Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks

## TRAINING STRATEGIES

### B. Sequence-Level Training 序列(句子)级别的训练

RL algorithms reinforcement learning 增强学习 (强化学习)

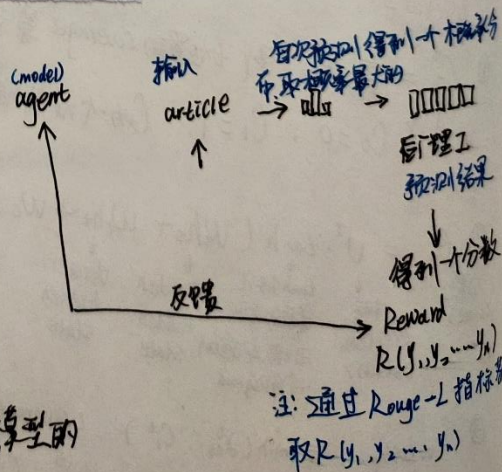
强化学习过程如下:

- ① 取一个模型 agent
- ② 初始化, 并进行预测
- ③ 用预测结果更新 agent

注: 强化学习资料:

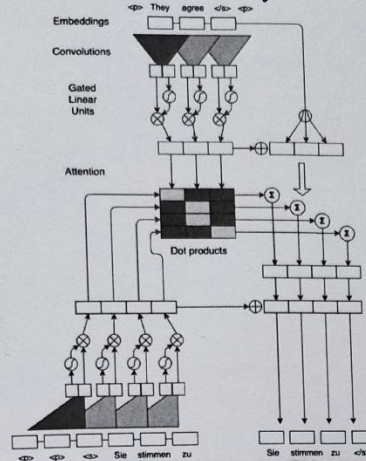
1. 网站: 知乎

RL 不是通过反向梯度求导来更新模型的  
(没有交叉熵, 没有 loss 概念)



# Beyond RNN (现在用的不多) 之前在翻译网络中用的较多

CNN



Position Embedding

层叠CNN构成了hierarchical representation表示

融合了Residual connection、liner mapping的多层attention

采用GLU做为gate mechanism

进行了梯度裁剪和精细的权重初始化, 加速模型训练和收敛

Convolutional Sequence to Sequence Learning

14


Beyond RNN为了解决GRU和LSTM不能并行计算的问题

CNN: Convolutional Neural Networks 卷积神经网络

## Beyond RNN

用Transformer替换LSTM, gru等神经网络  
 短视频中有transformer的基础介绍

Encoder



$P_{vocab} \times P_{gen}$

与Encoder中的结构相同  
 与Encoder中的结构有差异

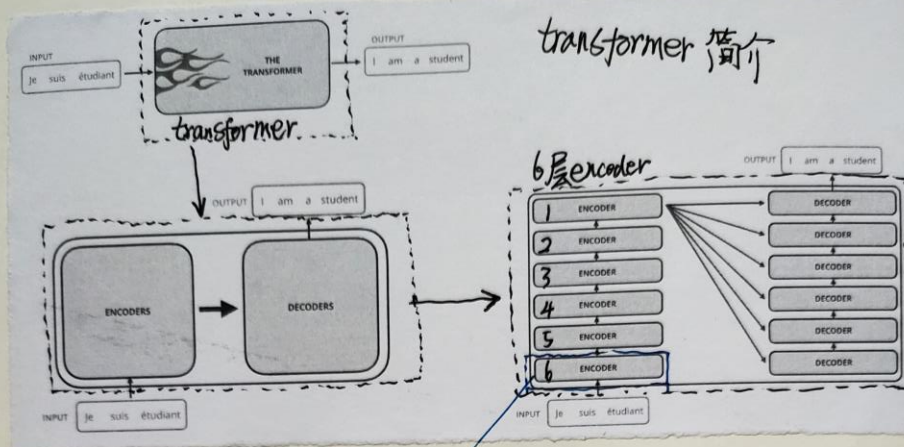
Decoder

Transformers and Pointer-Generator Networks for Abstractive Summarization

15


此处的embedding不是词向量





词与词之间的关系


Layer: 5 Attention: Input - Input



双层神经网络

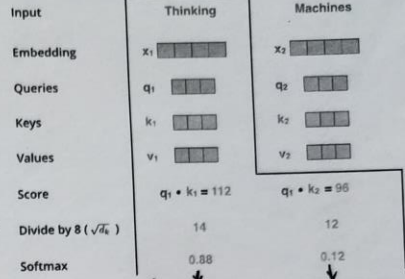


做 multi head 得到 到 2

Embedding 不是词向量



输入: 2个词

# Self-Attention 计算




dim为8的  
维度, 4x8

Thinking与Thinking  
的关系

Thinking与  
Machines的关系

由词  
构成  
句子



$$\text{softmax} \left( \frac{Q \cdot K^T}{\sqrt{d_k}} \right) \cdot V$$

= Z  $\Rightarrow$  Multi-headed  $\Rightarrow$  Z



## Multi-headed

重复多次 self-attention 操作, 计算不同维度的词的关系

利用多个头进行计算

因为初始维

矩阵不同

计算结果也不同

ATTENTION HEAD #0

$Q_0$

$K_0$

$V_0$

$W_0^Q$

$W_0^K$

$W_0^V$

ATTENTION HEAD #1

$Q_1$

$K_1$

$V_1$

$W_1^Q$

$W_1^K$

$W_1^V$

## Multi-headed

1) This is our input sentence\*

2) We embed each word\*

3) Split into 8 heads. We multiply  $X$  or  $K$  with weight matrices

4) Calculate attention using the resulting  $Q/K/V$  matrices

5) Concatenate the resulting  $Z$  matrices, then multiply with weight matrix  $W^O$  to produce the output of the layer

Thinking Machines

$X$

$W_0^Q$

$W_0^K$

$W_0^V$

$Q_0$

$K_0$

$V_0$

$Z_0$

$W^O$

$Z$

\* In all encoders other than #0, we don't need embedding. We start directly with the output of the encoder right below this one

$R$

$W_1^Q$

$W_1^K$

$W_1^V$

$Q_1$

$K_1$

$V_1$

$Z_1$

$W^O$

$Z$

$W_7^Q$

$W_7^K$

$W_7^V$

$Q_7$

$K_7$


$V_7$

$Z_7$

$W^O$

$Z$

Layer normalization



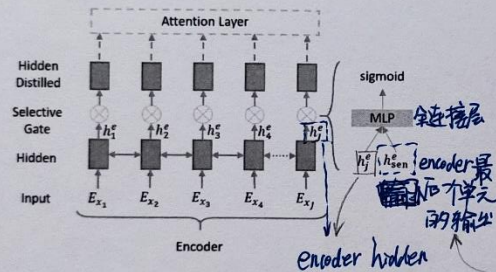
## Other Studies

- 1) Network Structure and Attention
- 2) Extraction + Abstraction
- 3) Long Documents

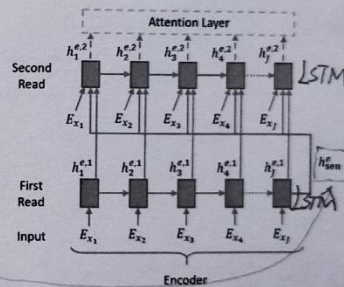
## Improving Encoded Representations

对Encoder改进

### Selective Encoding



### Read-Again Encoding



## Improving Decoder 对Decoder的改进思想

### Embedding Weight Sharing 共享权重

### Extraction + Abstraction

Extractor + Pointer-Generator Network

Key-Information Guide Network (KIGN)

Reinforce-Selected Sentence Rewriting



## SUMMARY GENERATION

### Diverse Beam Decoding

the top-B hypotheses may differ by just a couple tokens at the end of sequences, which not only affects the quality of generated sequences but also wastes computational resources

## Outline

- OOV 和Word-repetition解决
- Training Strategies
- 抽提式文本摘要基本方法
- 相关代码实践

## Text summarization

### Extractive text summarization 抽提式文本摘要

Source Text: Peter and Elizabeth took a taxi to attend the night party in the city.

从原文中抽取

While in the party, Elizabeth collapsed and was rushed to the hospital.

Summary: Peter and Elizabeth attend party city. Elizabeth rushed hospital.

### Abstractive text summarization

Source Text: Peter and Elizabeth took a taxi to attend the night party in the city.

While in the party, Elizabeth collapsed and was rushed to the hospital.

Summary: Elizabeth was hospitalized after attending a party with Peter.

# Extractive Text Summarization

抽取式文本摘要步骤:

对词进行表征: 如词向量, one-hot, tfidf

① 输入文本表征的构建

topic

representation

方法 { Frequency-driven Approaches  
Latent Semantic Analysis  
Bayesian Topic Models

② 根据表征给句子打分

indicator

representation

方法 { Graph Methods  
Machine Learning

③ 根据一定数量的句子组合


## Graph Methods

TextRank算法

jupyter 1ecwe-5

有此图用代码

传统机器学习方法



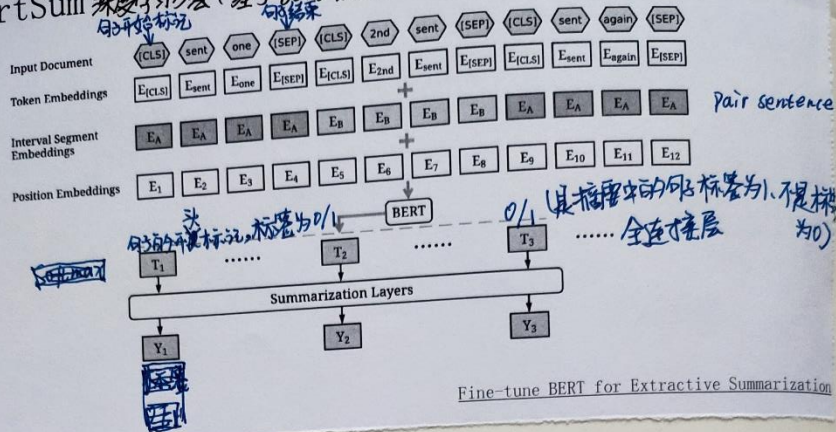
1. 第一步是把所有文章整合成文本数据
2. 接下来把文本分割成单个句子
3. 然后, 我们将为每个句子找到向量表示 (词向量)
4. 计算句子向量间的相似性并存放在矩阵中

5. 然后将相似矩阵转换为以句子为节点、相似性得分为边的图结构, 用于句子TextRank计算





## BertSum 预训练方法 (基于 bert 改造的)



注: (1) bert是无监督学习

(2) bert是自编码结构

(3) bert是一个字一个字切分的 (切分的单位为字, 今天星期几-1)

(4) bert 模型缺点: 模型大

bert在训练时, 15%的词会被 mask (掩盖) 掉, 其中 (这15%中) 的80%会完全被mask (类似空型), 10%的给错误词, 10%的给正确词

bert就是很多层 transformer 的编码器, 做相邻语句的断任务, 实现无监督训练

给定上一个词, 预测下一个词为自回归问题, bert为自编码问题

bert只有encoder, 没有decoder.

## Outline

- OOV 和 Word-repetition 解决
- Training Strategies
- 抽提式文本摘要基本方法
- 相关代码实践

附：

- (1) transformer 模型 github: <https://github.com/huggingface/transformers>
- (2) 文章: BERT-Pre-training of Deep Bidirectional Transformers for Language Understanding:  
<https://arxiv.org/pdf/1810.04805.pdf>  
(翻译博文: [https://blog.csdn.net/sinat\\_33741547/article/details/86311310](https://blog.csdn.net/sinat_33741547/article/details/86311310))
- (3) bert 模型 github: <https://github.com/jihun-hong/Bert-Classifier/tree/master/src/models>